



이미지 데이터 분석 (2일차)

합성곱 신경망 Convolutional Neural Network

다층 신경망에 이미지 입력

- 이미지는 2차원
- 다층 신경망의 입력은 1차원
- 이미지를 2차원 → 1차원으로 flattening하여 입력



Flattening



다층신경망의 문제점

- 2차원 이미지를 1차원으로 flatten하면서 공간적 정보가 사라짐
- dense 레이어는 입력의 크기 \times 출력의 크기만큼 파라미터가 필요하므로, 이미지의 크기가 커지면 파라미터가 폭증

이미지의 2차원 공간적 정보



필터 filter

- 이미지에 여러 가지 필터를 적용할 수 있음
 - 흐리기(blur)
 - 날카롭게(sharpen)
 - 경계선(edge)
- 이러한 필터는 합성곱(convolution)이라는 계산을 이용

합성곱 convolution

이미지

0	0	0	0	0
0	1	1	1	0
0	1	1	1	0
0	1	1	1	0
0	0	0	0	0

필터

-1	0	1
-1	0	1
-1	0	1

결과

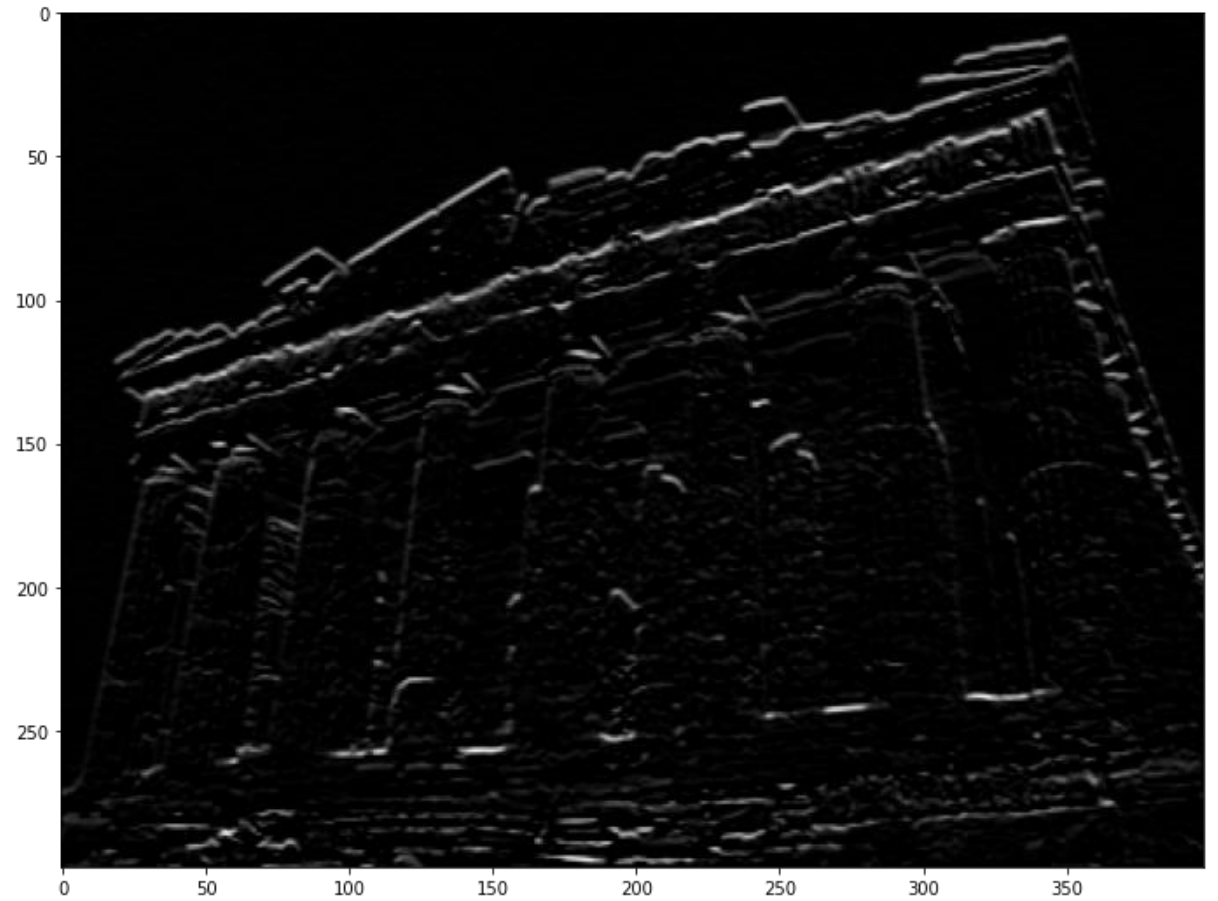
허리게




왼쪽 수직선



위쪽 수평선




윤곽선




합성곱 레이어 convolutional layer

- 작은 크기의 필터를 반복 적용
- 부분적인 패턴을 인식
- 필터의 값은 데이터로부터 학습




Dense Layer




Conv1D Layer

국소적으로 연결된 신경망

Fully connected neural net

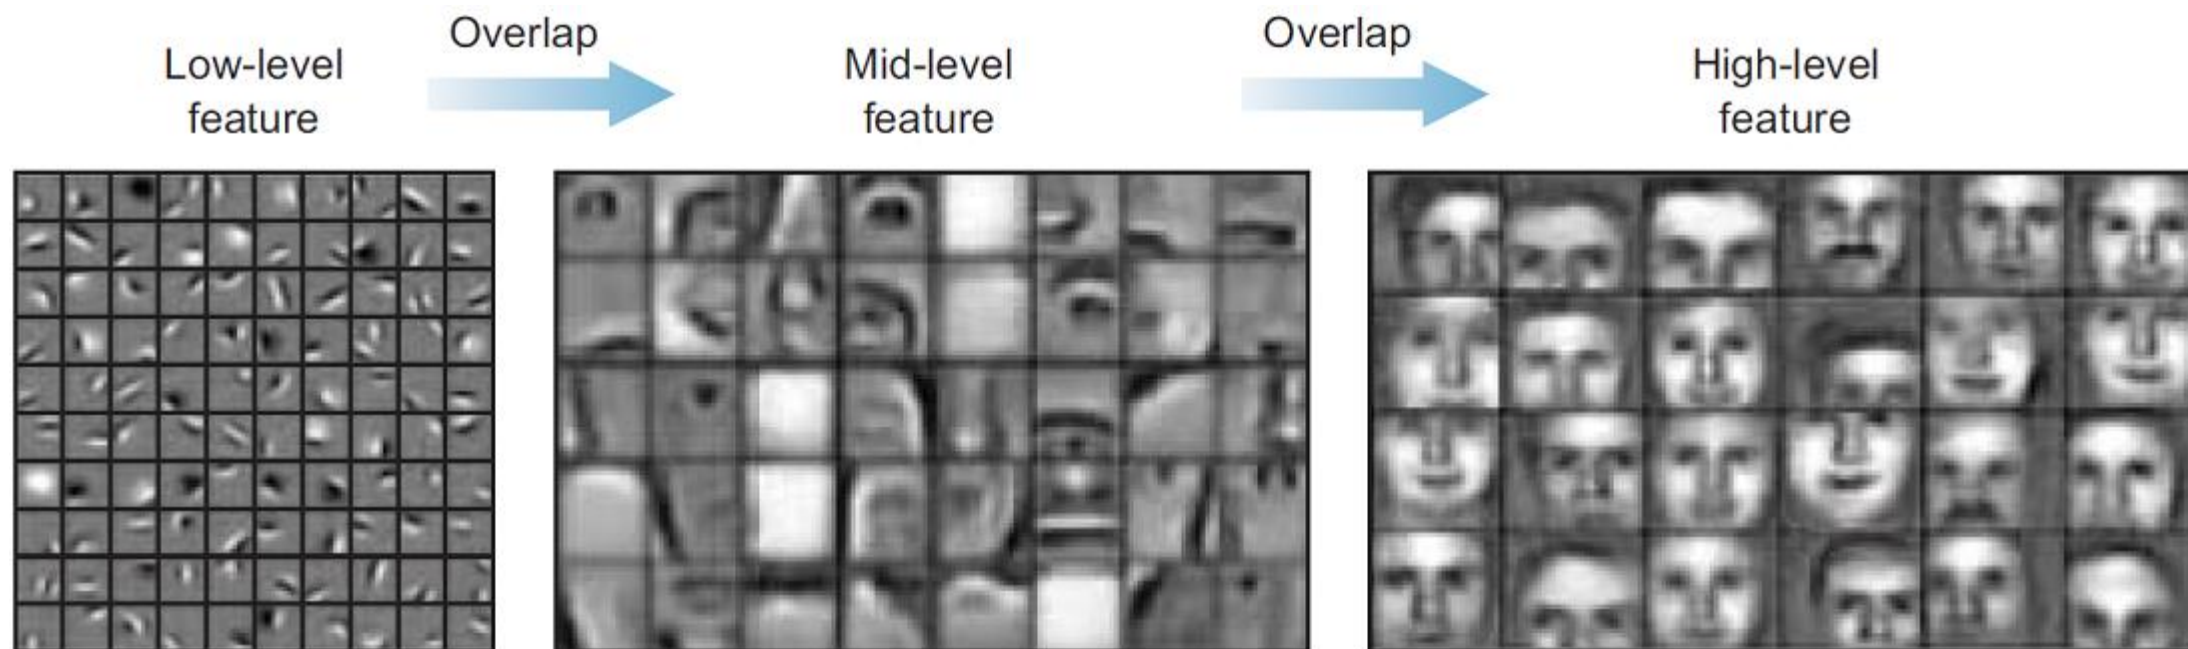


Locally connected neural net



합성곱 신경망 convolutional neural network


- 국소적으로 연결된 구조를 가지고 있어 이미지에서 부분적 특징을 추출할 수 있는 특성을 가진 신경망



CNN의 기본 구성 요소


- 합성곱 레이어 (Conv)
- 풀링 레이어 (Pool)
- 완전연결 레이어 (Fully Connected, Dense)

합성곱 레이어



Receptive Field

- 이미지에서 필터가 적용되는 영역



Kernel 또는 Filter

Input image



Edge detection
kernel

$$\begin{matrix} * & \begin{matrix} \begin{matrix} 0 & -1 & 0 \\ -1 & 4 & -1 \\ 0 & -1 & 0 \end{matrix} \end{matrix} & = \end{matrix}$$

Convolved image
(feature map)



feature map

- 합성곱 레이어의 출력 결과
- 이미지에서 발견된 특징을 사상(map)한 것이므로 feature map이라고 함
- 앞 장에서의 필터는 외곽선을 탐지하므로, 그 feature map은 외곽선

Pooling / subsampling / downsampling

- 이미지 또는 feature map의 크기를 축소
- 이미지의 세부적인 특징이 전체 이미지를 분류하는데 크게 중요하지 않은 경우가 많으므로 성능에는 영향이 적음
- 적용할 합성곱 레이어의 수가 줄어들음 → 학습할 파라미터가 줄어들음

A large, bold, black capital letter 'A' on a white background.

Original

A smaller, bold, black capital letter 'A' on a white background, representing the result of downsampling the original image.

Downsampled


풀링의 종류

- Max Pooling: 이미지에서 작은 부분(예: 2x2)들에서 최댓값을 추출
- Average Pooling: 이미지에서 평균값을 추출
- Max Pooling은 작은 영역에서 가장 강한 특징을 추출. 더 많이 사용


Stride

- stride: 필터를 적용하는 간격
- 풀링을 사용하는 대신 필터를 일정 간격으로 띄워서 사용하기도 함


합성곱 적용의 효과



풀링 적용의 효과



합성곱과 풀링 적용의 효과




완전 연결 레이어

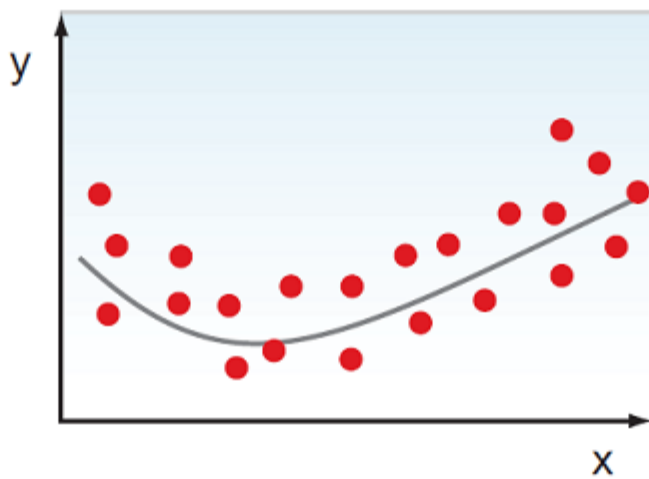
- 합성곱 신경망의 전반부에는 부분적 특징들을 추출하기 위해 국소적으로 연결된 합성곱 레이어를 사용
- 합성곱 신경망의 후반부에는 추출된 특징을 바탕으로 최종 예측을 하기 위해 완전 연결 레이어를 사용

과적합

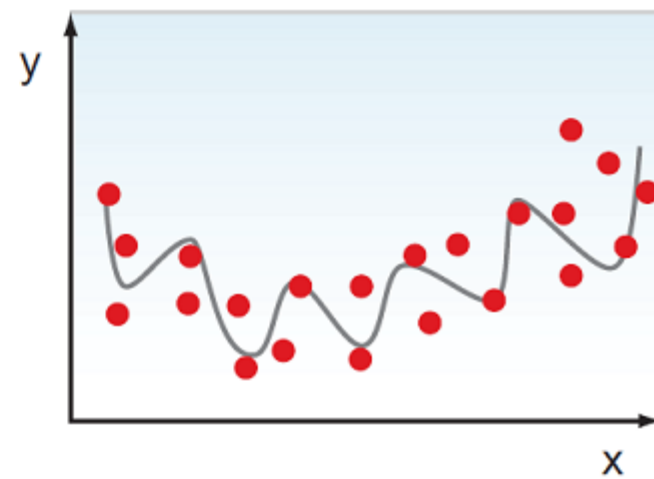
Underfitting



Just right!




Overfitting



Dropout

- 학습 과정에서 입력층과 은닉층의 출력값을 무작위로 0으로 대체
- 특정한 특징에 과적합되는 것을 방지



Dropout 레이어


- 일반적으로 합성곱 레이어 사이에는 잘 넣지 않고, 완전연결 레이어 사이에 넣음 (경험적 지식, 명확한 이유는 모름)
- Dropout의 비율은 0~1 사이에서 조정 (0.5 권장)
- 예측시에는 Dropout을 하지 않고, 출력을 Dropout한 비율로 조정

컬러 이미지의 처리

- 2차원 대신 3차원으로 입력 (예: $28 \times 28 \times 3$)
- 필터도 2차원 \rightarrow 3차원
- RGB 각 채널 별로 필터를 적용하고 결과를 더하는 것과 같음
- 출력의 크기 = $28 \times 28 \times (\text{필터의 수})$


데이터 분할

- 데이터를 Training과 Testing으로 분할 (보통 8:2 또는 9:1)
- 파라미터를 추정하는데는 많은 데이터가 필요하므로 Training을 크게
- Testing은 모형들의 성능을 구별할 정도만 되면 충분하므로 작게
- Training에 과적합되면 Testing에서 성능이 낮아짐
- Training과 Testing의 데이터가 섞이지 않도록 유의



Validation 또는 Development set

- 딥러닝에서는 다양한 하이퍼파라미터의 결정이 필요
- 테스트셋 데이터를 이용해서 결정하면 하이퍼파라미터가 테스트셋에 과적합될 우려
- 별도의 Validation 또는 Development set을 이용해서 하이퍼파라미터를 결정



과적합의 진단

- training set에서는 성능이 높지만 validation set에서는 성능이 낮을 경우
→ overfitting 되었을 가능성이 높음 → 모형의 복잡도/용량을 낮추는 방향으로 구조/하이퍼파라미터를 조정
- training set에서도 성능이 낮을 경우 → underfitting이 되었을 가능성이 높음 → 모형의 복잡도/용량을 높이는 방향으로 구조/하이퍼파라미터를 조정

베이지스 오차 Bayes Error

- 오차 0%는 다양한 이유로 실현 불가능(예: 테스트 이미지의 레이블이 잘못 붙어 있음. 식별 불가능한 이미지 등)
- 베이지스 오차: 데이터로부터 도달할 수 있는 이론적으로 최소의 오차
- 베이지스 오차를 실제로 추정하기는 불가능
- 보통 사람의 오차를 베이지스 오차 대용으로 사용

파라미터 vs. 하이퍼파라미터

- 파라미터
 - 데이터로부터 학습되는 변수
 - 신경망에서 가중치
 - 역전파 알고리즘을 통해 학습
- 하이퍼파라미터
 - 모형 또는 학습의 특성을 정의하는 변수
 - 학습 전에 결정
 - 신경망의 크기, 구조, 학습률, 배치의 크기 등

신경망에서 하이퍼 파라미터의 종류


- 신경망의 구조: 은닉층의 수, 각 층의 폭, 활성화 함수
- 학습 및 최적화: 학습률, 배치의 크기, 최적화 알고리즘, 에포크 수, 학습 중단 방식
- 정규화: 드롭아웃 방식, 데이터 증강 등

하이퍼파라미터 튜닝 hyperparameter tuning

- 하이퍼파라미터: 모형의 성격이나 학습 방법과 관련된 설정
- 학습률, 은닉층의 수, 은닉층의 크기 등
- 데이터로부터 학습될 수 없고 시행착오를 통해 튜닝
- 보통 1, 2, 3, ...이 아니라 1, 10, 100, ... 등으로 탐색


격자 탐색 grid search

- 하이퍼파라미터가 여러 종류일 경우
- 각 하이퍼파라미터의 설정값을 정하고, 이들을 조합하여 하나씩 시도




무작위 탐색 random search

- 하이퍼파라미터를 무작위로 조합하여 하나씩 시도



무작위 탐색이 더 나은 이유

- 모형의 성능은 특정한 하이퍼파라미터에 좌우
- 무작위 탐색이 각각의 하이퍼파라미터를 더 다양하고 촘촘하게 탐색



무작위 탐색의 문제점

- 하이퍼파라미터의 종류가 많아질 수록 더 많은 탐색이 필요
- 하이퍼파라미터는 학습 전체가 끝나야 성능을 알 수 있음 (비쌈)
- 무작위 탐색은 이전의 학습 결과를 활용하지 않음

Sequential Model-Based Optimization

- 하이퍼파라미터와 성능의 관계를 모형화
- 모형을 바탕으로 최적의 하이퍼파라미터를 선택하여 학습
- 학습 결과를 바탕으로 모형을 수정
- 위의 과정을 반복

양성과 음성 positive and negative

- 이항분류 binary classification: 두 가지 범주 중에 하나로 분류하는 것
- 양성 positive: 탐지하고자 하는 대상이 있음. (예: 암, 불량, 화재 등)
- 긍정적이라는 의미의 양성 benign이 아님
- 음성 negative: 탐지하고자 하는 것이 없음.

혼동 행렬 confusion matrix

실제

음성 (0)

--

양성 (1)



--

혼동 행렬 confusion matrix

예측

음성 (0)

양성 (1)





혼동 행렬 confusion matrix

예측

음성 (0)

양성 (1)

음성 (0)



양성 (1)



실제

혼동 행렬 confusion matrix

예측

음성 (0)

양성 (1)

실제

음성 (0)

진음성
True Negative

위양성
False Positive

양성 (1)

위음성
False Negative

진양성
True Positive

진/위 양성/음성

- 혼동행렬에서 양성/음성은 예측을 기준으로 말함
- 현실에서는 실제로 어떤지 알 수 없는 경우가 많음
- 진(True) → 예측이 맞음
- 위(False) → 예측이 틀림

정확도 accuracy

예측

음성 (0)

양성 (1)

실제

음성 (0)



양성 (1)



정확도 accuracy

- 전체 중에 예측이 맞은 비율

$$\frac{TP + TN}{\text{전체}}$$

- 특별히 음성/양성 구분에 관심이 없는 경우 사용
- 그러나 대부분은 양성에 더 관심이 있음

정밀도 precision



예측

음성 (0)

양성 (1)

실제

음성 (0)



양성 (1)



정밀도 precision

- 양성 예측 중에 맞은 비율

$$\frac{TP}{TP + FP}$$

- 양성 예측이 중요한 경우 (예: 채용)
- 대체로 문턱값을 높이면(보수적 예측) 정밀도가 높아진다

문턱값 threshold

예측

음성 (0)


양성 (1)

실제

음성 (0)



양성 (1)



문턱값 threshold


예측

음성 (0)



양성 (1)

실제

음성 (0)



양성 (1)



문턱값을 높이면



예측

음성 (0)



양성 (1)

실제

음성 (0)



양성 (1)



문턱값을 낮추면


예측

음성 (0)




양성 (1)

실제

음성 (0)



양성 (1)



재현도 recall



예측

음성 (0)

양성 (1)

실제

음성 (0)



양성 (1)



재현도 recall

- 실제 양성 중 찾아낸 비율

$$\frac{TP}{TP + FN}$$

- 양성을 찾아 내는 것이 중요한 경우 (예: 방역)
- 의학 등에서는 민감도(specificity)라고도 함
- 대체로 문턱값을 낮추면(적극적 예측) 재현도가 높아진다

문턱값 threshold



예측

음성 (0)

양성 (1)

실제

음성 (0)



양성 (1)





문턱값을 높이면

예측

음성 (0)



양성 (1)

음성 (0)



실제

양성 (1)



문턱값을 낮추면

예측


음성 (0)

양성 (1)

실제

음성 (0)

양성 (1)



특이도 specificity

- 실제 음성 중 찾아낸 비율

$$\frac{TN}{TN + FP}$$

- 음성을 찾아 내는 것이 중요한 경우 (예: 방역)
- 대체로 양성 예측을 보수적으로 하면 특이도가 높아진다

F1

- 정밀도(p)와 재현도(r)의 조화 평균


$$\frac{1}{\frac{\frac{1}{p} + \frac{1}{r}}{2}} = \frac{2pr}{p + r}$$

- 조화평균: 역수의 평균의 역수
- 비율, 속도 등을 평균낼 때는 산술평균 대신 조화평균을 사용


ROC 곡선

- Receiver operating characteristic
- 신호 이론에서 유래
- 가로축은 1-특이도, 세로축은 재현도
- 문턱값을 변화시키면서 특이도와 재현도의 변화를 곡선으로 표시


ROC 곡선



ROC 곡선



ROC 곡선



곡선하 면적 Area Under the Curve

- ROC 곡선 아래의 면적 (약칭 AUC)
- 0~1 범위
- 무작위로 예측할 경우 0.5
- 1에 가까울 수록 성능이 높음